

EVALUACIÓN 1

Calidad y Preparación de Datos

*Rendimiento Académico
en Educación Superior*

PRESENTACIÓN

Diagnóstico, Análisis Exploratorio y Tratamiento del Dataset

INTEGRANTES

Juan Riquelme
Yoseph Rodriguez
Felipe Soto

FECHA

04 Septiembre de 2026

El dataset y su objetivo

OBJETIVO

Diagnosticar la calidad de los datos, realizar un análisis exploratorio y definir e implementar (Pipeline + ColumnTransformer) estrategias de tratamiento para obtener un dataset final limpio.

REGLA METODOLÓGICA

El dataset no se modifica durante el diagnóstico ni el análisis exploratorio. El tratamiento se implementa exclusivamente después de justificar cada decisión.

5.100

registros iniciales

11

variables

Variable	Tipo de dato	Naturaleza	Descripción
StudentID	Texto (string)	Nominal / Identificador	Código único del estudiante.
Age	Numérica (float)	Continua	Edad del estudiante en años.
StudyHours	Numérica (float)	Continua	Horas de estudio dedicadas por semana .
Attendance	Numérica (float)	Continua	Porcentaje de asistencia a clases.
PreviousGPA	Numérica (float)	Continua	Promedio académico previo (escala 1.0-10.0).
AssignmentsCompleted	Numérica (float)	Continua	Porcentaje de tareas/actividades completadas.
SleepHours	Numérica (float)	Continua	Horas de sueño por día .
InternetHours	Numérica (float)	Continua	Horas de uso de internet por día .
Scholarship	Categorica (object)	Nominal	Indica si el estudiante posee beca.
Program	Categorica (object)	Nominal	Programa académico que cursa el estudiante.
FinalGrade	Numérica (float)	Continua	Calificación final del curso (escala 1.0-10.0).

Principales problemas encontrados

9 / 11

Variables con valores faltantes

Entre 1,37% (Program) y 4,39% (Attendance)

100

Registros duplicados

2,0% del dataset — filas idénticas por StudentID

8 / 13

Categorías mal formateadas

Variantes de mayúsculas, tildes y espacios en Scholarship y Program

63

Valores fuera de dominio

Físicamente imposibles: asistencia negativa, +24h diarias, notas fuera de escala

8 / 11

Variables con atípicos (IQR)

Entre 0,33% y 2,84% según variable — válidos vs. inválidos

Nueve de las once variables presentan valores faltantes (< 5% cada una); no se observa un patrón de pérdida no aleatoria, por lo que se opta por imputación en vez de eliminación de filas o columnas.

Valores faltantes por variable

Variable	Nulos_Absolutos	Porcentaje_Nulos
Attendance	224	4.39
AssignmentsCompleted	216	4.24
StudyHours	181	3.55
InternetHours	176	3.45
PreviousGPA	162	3.18
SleepHours	122	2.39
Age	103	2.02
Scholarship	81	1.59
Program	70	1.37

LECTURA

- Rango entre 1,37% y 4,39% — bajo en todas las variables.
- StudentID y FinalGrade no presentan nulos.
- Se descarta eliminar filas o columnas: se pierde información innecesariamente.

Duplicados e inconsistencias de formato

REGISTROS DUPLICADOS

100

2,0% del dataset

Filas completamente idénticas. Los duplicados por StudentID coinciden exactamente con los duplicados por fila completa: es la misma observación repetida.

Decisión: eliminar, conservando la primera ocurrencia (keep="first").

INCONSISTENCIAS DE FORMATO

Scholarship

8 valores únicos

en vez de 2 (Sí / No)

Program

13 valores únicos

en vez de 5 programas

Causa: variaciones de mayúsculas, minúsculas, tildes y espacios en blanco (ej. "si", "SI", "NO", "No ", "Sí ").


Decisión: normalizar y consolidar en las categorías canónicas

Valores fuera de dominio (inválidos)

VARIABLE	PROBLEMA	CASOS	ESTRATEGIA
Attendance	Porcentaje fuera de [0, 100]	20 (0,39%)	Recodificar a NaN e imputar
SleepHours	Horas diarias negativas	8 (0,16%)	Recodificar a NaN e imputar
InternetHours	Horas diarias > 24	31 (0,61%)	Recodificar a NaN e imputar
StudyHours	Horas semanales > 168	0 (0,00%)	Regla de control; sin casos
PreviousGPA	Fuera de escala [1,0–10,0]	0 (0,00%)	Regla de control; sin casos
FinalGrade	Fuera de escala [1,0–10,0]	4 (0,08%)	Recodificar a NaN e imputar
Age	Fuera de escala [17,100]	0 (0,00%)	Regla de control; sin casos
AssignmentsCompleted	Fuera de escala [0,100]	0 (0,00%)	Regla de control; sin casos

Estos valores son lógicamente imposibles dado el significado de cada variable (un porcentaje no puede ser negativo, un día no tiene más de 24 horas). Se tratan como errores de captura, no como atípicos válidos.

Valores atípicos: inválido vs. válido



Principales decisiones de tratamiento

PROBLEMA	ESTRATEGIA	JUSTIFICACIÓN
Duplicados (100)	Eliminar, conservar 1ª ocurrencia	Copias exactas; no aportan información nueva
Formato Scholarship / Program	Normalizar y consolidar categorías	Variantes de escritura de la misma categoría
Valores fuera de dominio	Recodificar a NaN e imputar	Físicamente imposibles; no se pueden "adivinar"
Nulos(baja dispersión)	Imputar por media	PreviousGPA, AssignmentsCompleted, Attendance, SleepHours
Nulos(mayor dispersión)	Imputar por mediana	Age, StudyHours, InternetHours — más robusta a atípicos
Nulos categóricos	Imputar por moda	Scholarship, Program

Clasificación de dispersión según análisis IQR: Baja <1%, Mayor >1%

Principales resultados del EDA

¿Beca y rendimiento?

Diferencia de 0,30 puntos

Con beca: 4,37 · Sin beca: 4,07 (escala 1,0–10,0). Consistente, aunque discreta.

	count	mean	std
Scholarship			
No	3364	4.074	1.005
Sí	1620	4.371	0.932

¿Mejor programa académico?

Ingeniería Informática

4,23 vs. 4,05 de Contador Auditor. Brecha de solo 0,18 puntos entre programas.

	count	mean	std
Program			
Ingeniería Informática	1424	4.232	0.988
Administración	787	4.217	1.009
Ingeniería Industrial	1119	4.201	0.982
Ingeniería Civil	1004	4.108	0.986
Contador Auditor	660	4.045	1.003

¿Horas de estudio y nota?

Correlación $r \approx 0,49$


Relación positiva de intensidad moderada; más horas de estudio, mejor nota final.

¿Asistencia y nota?

Correlación $r \approx 0,59$

El promedio de FinalGrade aumenta de forma sostenida entre cuartiles de asistencia.

Correlación de las variables con FinalGrade



LECTURA PRINCIPAL

AssignmentsCompleted (0,68) y **PreviousGPA** (0,65) son los factores más asociados al rendimiento final.

Attendance (0,59) y **StudyHours** (0,49) siguen en importancia.

SleepHours, **Age** e **InternetHours** tienen correlación prácticamente nula.

Conclusiones generales del EDA

1

Comportamiento durante el curso > características demográficas

El cumplimiento de tareas y el rendimiento previo pesan más que edad, sueño o uso de internet en el resultado final.

2

La beca se asocia a mejor rendimiento, con diferencia discreta

0,30 puntos de diferencia frente a una desviación estándar de la nota de $\approx 1,0$.

3

El programa académico no explica diferencias importantes

Brecha de apenas 0,18 puntos entre el mejor y el peor programa: el rendimiento es relativamente homogéneo entre carreras.

Estado final de la calidad de los datos

INDICADOR	DATASET ORIGINAL	DATASET TRATADO
Cantidad de registros	5.100	5.000
Cantidad de variables	11	16
Valores faltantes (total)	1335	0
Registros duplicados	100	0
Inconsistencias (fuera de dominio)	63	0
Outliers inválidos tratados	63	0

El dataset tratado no presenta valores faltantes ni duplicados. Las variables numéricas quedan dentro de su dominio válido, y las categóricas reducidas a sus categorías canónicas (2 y 5). Los atípicos válidos se conservan, atenuados mediante RobustScaler.

Dataset final

	StudentID	PreviousGPA	AssignmentsCompleted	Attendance	SleepHours	Age	StudyHours	InternetHours
0	STU-10522	0.525754	-1.154173	-0.096829	-0.601737	-0.2	-0.205894	-0.324698
1	STU-10947	1.456325	-0.593760	1.464960	-0.397124	8.4	-0.337917	0.513529
2	STU-11352	0.497976	0.774224	0.781001	-0.249803	0.6	0.223183	0.131261
3	STU-12298	-0.863157	0.412830	-0.293652	-0.691766	0.8	1.376817	0.002303
4	STU-13527	-1.210384	-1.509820	-1.431289	-0.577183	-0.6	-0.902161	-0.391480

Scholarship_No	Scholarship_Sí	Program_Administración	Program_Contador Auditor	Program_Ingeniería Civil	Program_Ingeniería Industrial	Program_Ingeniería Informática	FinalGrade
0.0	1.0	0.0	0.0	0.0	1.0	0.0	3.96
1.0	0.0	0.0	0.0	0.0	0.0	1.0	5.09
1.0	0.0	0.0	1.0	0.0	0.0	0.0	4.37
1.0	0.0	0.0	1.0	0.0	0.0	0.0	4.02
1.0	0.0	0.0	0.0	1.0	0.0	0.0	3.24